UANL
UNIVERSIDAD AUTÓNOMA DE NUEVO LEÓN

FIME
FACULTAD DE INGENIERÍA MECÁNICA Y ELÉCTRICA

UNIVERSIDAD AUTÓNOMA DE NUEVO LEÓN

FACULTAD DE INGENIERÍA MECÁNICA Y ELÉCTRICA

INTELIGENCIA ARTIFICIAL Y REDES NEURONALES

Docente: Ing. Daniel Isaías López Páez

Actividad Fundamental #6 Aprendizaje Supervisado, árbol de decisión

Nombre	Matrícula	Carrera
Sergio Alejandro De Luna Martínez	2223094	IMC
Luis Fernando Coronado Gómez	2178070	IMC
Rubén Alejandro Reyes Estrada	2051186	IMC
Alejandro Delgado de León	2103173	IMC
Rodrigo Rodríguez Saavedra	2094324	IMC

Grupo: 004 **Día y hora:** Jueves N1

San Nicolás de los Garza, Nuevo León, a 15 de octubre del 2026

Objetivo.-

El estudiante entrenará un modelo de árbol de decisión en Google Colab utilizando el lenguaje de programación Python. Este modelo usará el conjunto de datos "Breast Cancer Wisconsin (Diagnostic)", que contiene características calculadas a partir de imágenes digitalizadas de tumores de cáncer de mama y su correspondiente diagnóstico (maligno o benigno).

Introducción al tema:

Modelos de aprendizaje supervisado, árbol de decisión

En la actualidad, la inteligencia artificial se utiliza en diferentes áreas para resolver problemas, analizar información y facilitar la toma de decisiones. Una de las formas en que una computadora puede aprender a realizar estas tareas es mediante el **aprendizaje automático**, también conocido como **Machine Learning**. Dentro de este campo existen diferentes modelos que permiten a las computadoras identificar patrones en los datos y utilizarlos para hacer predicciones.

Uno de estos métodos es el ***aprendizaje supervisado***, el cual consiste en entrenar un modelo utilizando datos que ya contienen información conocida sobre el resultado esperado. De esta manera, el sistema aprende la relación entre los datos de entrada y sus resultados para después aplicarla en situaciones nuevas.

Dentro de los modelos de aprendizaje supervisado se encuentra el ***árbol de decisión***, que es una herramienta que permite clasificar información o realizar predicciones mediante una serie de preguntas y condiciones. Su funcionamiento es parecido al proceso que sigue una persona cuando debe tomar una decisión a partir de diferentes opciones.

Hablando más a fondo, el ***aprendizaje supervisado*** es una rama del aprendizaje automático en la que un modelo aprende a partir de un conjunto de datos que ya tienen una respuesta conocida. Estos datos se utilizan durante el entrenamiento para que el sistema pueda identificar relaciones entre las características de cada ejemplo y el resultado correspondiente.

Por lo general, los datos de entrenamiento contienen dos elementos principales: **las características de entrada**, que son los datos que se utilizan para hacer una predicción, y la **etiqueta o resultado esperado**, que representa la respuesta correcta que el modelo debe aprender a predecir.

El aprendizaje supervisado se divide principalmente en dos tipos de problemas:

- **Clasificación:** se utiliza cuando el resultado pertenece a una categoría. Como cuando un correo es spam, determinar si una máquina presenta una falla o clasificar una imagen.
- **Regresión:** se utiliza cuando se busca predecir un valor numérico, como precio de un producto, por ejemplo.

Existen diferentes modelos que trabajan con aprendizaje supervisado, como la regresión lineal, las máquinas de soporte vectorial, las redes neuronales y los árboles de decisión. Cada uno tiene características particulares y puede ser más adecuado dependiendo del problema que se desea resolver.

Por otro lado, un ***árbol de decisión*** es un modelo de aprendizaje supervisado que utiliza una estructura parecida a un árbol para representar las decisiones y sus posibles resultados. Su propósito es analizar las características de los datos y establecer condiciones que permitan llegar a una predicción.

Este modelo está formado por tres elementos principales:

- **Nodo raíz:** es el punto inicial del árbol, donde se realiza la primera pregunta o división utilizando una característica de los datos.
- **Ramas:** representan las diferentes respuestas o caminos que se pueden seguir después de evaluar una condición.
- **Nodos hoja:** son los puntos finales del árbol, donde se encuentra la predicción o el resultado final.

Este tipo de modelo es útil porque permite observar cómo se obtiene una respuesta paso a paso. A diferencia de otros modelos que pueden ser más difíciles de

interpretar, un árbol de decisión normalmente permite seguir las condiciones que llevaron a una predicción.

El funcionamiento de un ***árbol de decisión*** comienza con la recopilación de datos relacionados con el problema que se desea resolver. Después, se organiza la información y se utiliza un conjunto de datos de entrenamiento para construir el modelo.

Durante el entrenamiento, el algoritmo busca qué características permiten separar mejor los datos según sus resultados. Para ello, realiza divisiones sucesivas, creando ramas que agrupan los ejemplos de acuerdo con determinadas condiciones.

En los problemas de clasificación, algunos de los criterios utilizados para elegir estas divisiones son la impureza de Gini y la entropía. En términos sencillos, estos criterios ayudan a medir qué tan mezcladas están las categorías dentro de un grupo. El algoritmo busca divisiones que formen grupos más claros y con resultados similares. En los problemas de regresión, puede utilizar medidas relacionadas con el error entre los valores reales y los valores predichos.

El proceso continúa hasta que se cumplen ciertas condiciones para detener el crecimiento del árbol, como alcanzar una profundidad máxima o tener muy pocos datos en una rama. Al finalizar, el modelo puede recibir nuevos datos y recorrer las condiciones del árbol hasta llegar a una hoja con la predicción correspondiente.

Es importante mencionar que un árbol demasiado complejo puede aprender detalles muy específicos de los datos de entrenamiento y tener dificultades para predecir correctamente en situaciones nuevas. Este problema se conoce como sobreajuste. Para reducirlo, se pueden limitar la profundidad del árbol, establecer un mínimo de datos por nodo o aplicar una técnica llamada poda, que consiste en eliminar ramas que no aportan suficiente beneficio al modelo.

Ventajas y desventajas del árbol de decisión

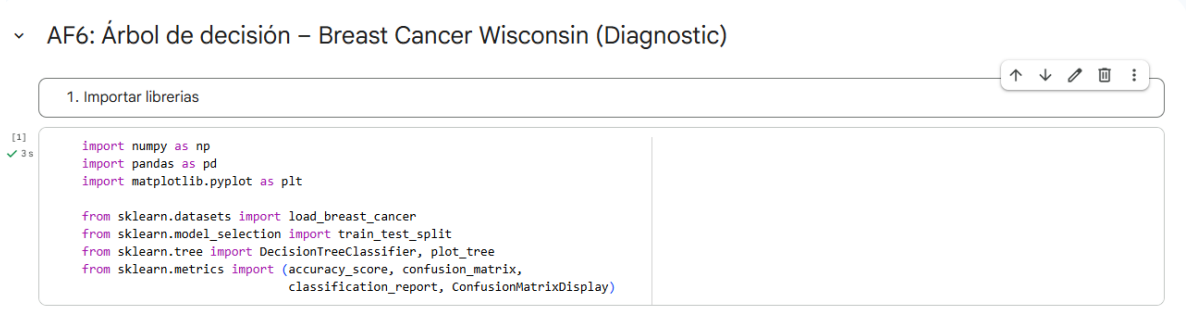
Una de las principales ventajas del árbol de decisión es que su funcionamiento suele ser fácil de comprender, ya que las decisiones se representan mediante condiciones y caminos. También puede trabajar con datos numéricos y categóricos, y es capaz de identificar relaciones entre distintas características sin necesitar que todas esas relaciones se definan manualmente.

Otra ventaja es que puede utilizarse en diferentes áreas, como la industria, la medicina, las finanzas y el control de calidad.

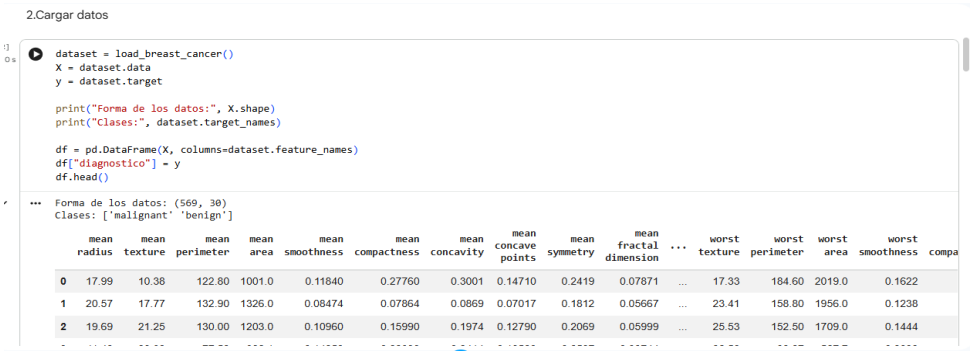
Sin embargo, este modelo también presenta algunas desventajas. Una de ellas es que puede cambiar bastante cuando se utilizan datos de entrenamiento diferentes. Además, si el árbol crece demasiado, puede generar reglas muy específicas que no funcionen bien con datos nuevos. También puede perder precisión cuando el problema es muy complejo y existen muchas relaciones difíciles de representar mediante divisiones sencillas.

METODOLOGÍA

1.Carga de librerías. Se importaron las bibliotecas necesarias para el desarrollo del proyecto. NumPy y pandas se emplearon para la manipulación de datos, y Matplotlib para la generación de gráficas. De scikit-learn se utilizaron el conjunto de datos, la función train_test_split para la partición de los datos, la clase DecisionTreeClassifier para la construcción del modelo, la función plot_tree para su representación gráfica y las métricas de evaluación accuracy_score, confusion_matrix y classification_report.



2. Carga de datos. Se utilizó el conjunto de datos Breast Cancer Wisconsin (Diagnostic), incluido en scikit-learn mediante la función load_breast_cancer(). Este conjunto contiene 569 observaciones descritas por 30 características numéricas, calculadas a partir de imágenes digitalizadas de tumores de mama, como el radio, la textura y el perímetro. Las observaciones se dividieron en una matriz de características (X) y un vector de etiquetas (y), donde cada diagnóstico se codifica como maligno (0) o benigno (1). Asimismo, se verificó la correcta carga de la información mediante la impresión del tamaño de los datos y de las clases.



2.Cargar datos

```
dataset = load_breast_cancer()
X = dataset.data
y = dataset.target

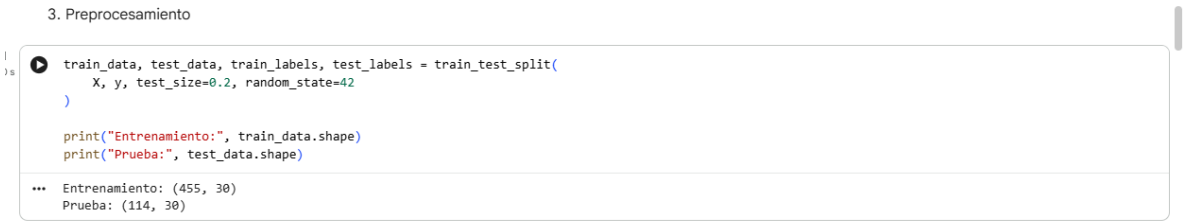
print("Forma de los datos:", X.shape)
print("Clases:", dataset.target_names)

df = pd.DataFrame(X, columns=dataset.feature_names)
df["diagnostico"] = y
df.head()
```

```
Forma de los datos: (569, 30)
Clases: ['malignant' 'benign']
```

	mean radius	mean texture	mean perimeter	mean area	mean smoothness	mean compactness	mean concavity	mean concave points	mean symmetry	mean fractal dimension	...	worst texture	worst perimeter	worst area	worst smoothness	compa
0	17.99	10.38	122.80	1001.0	0.11840	0.27760	0.3001	0.14710	0.2419	0.07871	...	17.33	184.60	2019.0	0.1622	
1	20.57	17.77	132.90	1326.0	0.08474	0.07864	0.0869	0.07017	0.1812	0.05667	...	23.41	158.80	1956.0	0.1238	
2	19.69	21.25	130.00	1203.0	0.10960	0.15990	0.1974	0.12790	0.2069	0.05999	...	25.53	152.50	1709.0	0.1444	

3. Preprocesamiento de datos. Con la función train_test_split se particionó el conjunto de datos en un 80 % para entrenamiento (train_data, train_labels) y un 20 % para prueba (test_data, test_label). Se estableció una semilla aleatoria (random_state=42) para garantizar la reproducibilidad de los resultados.



3. Preprocesamiento

```
train_data, test_data, train_labels, test_labels = train_test_split(
    X, y, test_size=0.2, random_state=42
)

print("Entrenamiento:", train_data.shape)
print("Prueba:", test_data.shape)
```

```
Entrenamiento: (455, 30)
Prueba: (114, 30)
```

4. Selección y entrenamiento del modelo. Se seleccionó un árbol de decisión, un modelo de aprendizaje supervisado que clasifica las observaciones mediante una serie de reglas jerárquicas basadas en los valores de las características. El modelo se entrenó con los datos de entrenamiento utilizando el método fit, con lo que aprendió los criterios que permiten distinguir entre tumores malignos y benignos.

4. Seleccion y entrenamiento del modelo

```
modelo = DecisionTreeClassifier(random_state=42)
modelo.fit(train_data, train_labels)
```

5. Prueba del modelo. Se realizaron predicciones sobre el conjunto de prueba, que el modelo no había observado durante el entrenamiento, mediante el método predict. Para evaluar su desempeño se obtuvo la matriz de confusión, que muestra la cantidad de clasificaciones correctas e incorrectas por clase. Además, se calculó la exactitud (accuracy) como métrica principal y se generó el reporte de clasificación, el cual resume la precisión, la sensibilidad (recall) y la puntuación F1 de cada clase.

5. Prueba del modelo

```
# Predicciones
predicciones = modelo.predict(test_data)

# Precisión
accuracy = accuracy_score(test_labels, predicciones)
print(f"Precisión (accuracy): {accuracy:.4f}\n")

# Reporte de clasificación
print("Reporte de clasificación:")
print(classification_report(test_labels, predicciones,
                            target_names=dataset.target_names))

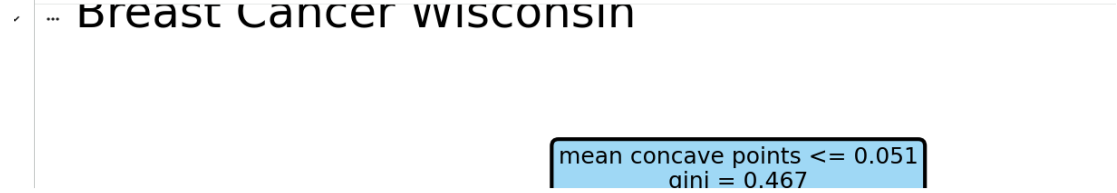
# Matriz de confusión
cm = confusion_matrix(test_labels, predicciones)
print("Matriz de confusión:\n", cm)

disp = ConfusionMatrixDisplay(confusion_matrix=cm,
                              display_labels=dataset.target_names)
disp.plot(cmap="Blues")
plt.title("Matriz de confusión")
plt.show()
```

6. Visualización del árbol. Finalmente, se generó la representación gráfica del árbol entrenado con una resolución de 300 DPI, donde se aprecian las condiciones de decisión de cada nodo y las clases asignadas en las hojas.

6. Visualizacion del arbol de decision

```
plt.figure(figsize=(25, 12), dpi=300)
plot_tree(modelo,
          feature_names=dataset.feature_names,
          class_names=dataset.target_names,
          filled=True,
          rounded=True,
          fontsize=6)
plt.title("Árbol de decisión - Breast Cancer Wisconsin")
plt.savefig("arbol_decision.png", dpi=300, bbox_inches="tight")
plt.show()
```



RESULTADOS

Para evaluar el modelo usamos el conjunto de prueba, que tiene 114 observaciones (43 tumores malignos y 71 benignos) que el árbol nunca vio durante el entrenamiento. La exactitud fue de 94.74 %, es decir, el modelo acertó en 108 de los 114 casos, lo cual es un buen resultado para un árbol de decisión.

En la matriz de confusión se ve que el modelo clasificó bien 40 tumores malignos y 68 benignos. Los errores fueron 6 en total: 3 casos malignos que predijo como benignos (falsos negativos) y 3 casos benignos que predijo como malignos (falsos positivos).

Link al repositorio:

https://colab.research.google.com/drive/1wJjvq7J9kgptfV8rdmS5iIKwlxjRtAZC?usp=sharing

CONCLUSIÓN GENERAL

El desarrollo de esta actividad permitió consolidar el entendimiento práctico e intuitivo del aprendizaje supervisado, centrándose en el algoritmo de Árboles de Decisión aplicado a un problema real de clasificación médica. A lo largo de la práctica, se abarcó el ciclo completo de desarrollo en Machine Learning: desde la ingesta de los datos del dataset *Breast Cancer Wisconsin (Diagnostic)* hasta la evaluación cuantitativa de la capacidad predictiva del modelo.

Una de las principales ventajas observadas de los árboles de decisión es su interpretabilidad. A diferencia de otros modelos de tipo "caja negra" (como las redes neuronales profundas), la estructura jerárquica del árbol permite rastrear de manera lógica y transparente cada regla de decisión tomada en los nodos de división. Esto resulta fundamental en entornos de diagnóstico médico, donde comprender las variables biomédicas o morfométricas críticas (como el radio, el perímetro o la textura celular) que determinan si una muestra es benigna o maligna aporta un valor explicativo indispensable para la toma de decisiones asistida.

La fase de prueba puso de manifiesto la importancia de separar adecuadamente los conjuntos de datos en entrenamiento (80%) y prueba (20%) mediante train_test_split. Este procedimiento garantizó que las métricas obtenidas reflejaran verdaderamente la capacidad de generalización del algoritmo frente a observaciones completamente nuevas. Las herramientas de evaluación utilizadas —la matriz de confusión, el informe de clasificación (classification_report) y el cálculo de la precisión (*accuracy*)— brindaron un panorama exhaustivo del desempeño. La matriz de confusión, en particular, permitió identificar no solo la tasa general de aciertos, sino también minimizar y comprender los posibles falsos positivos y falsos negativos, aspecto crítico en contextos diagnósticos.

REFERENCIAS:

- Arana, C. (2021, febrero). Modelos de aprendizaje automático mediante árboles de decisión (Documento de Trabajo No. 778). Universidad del CEMA. https://biblio.ucema.edu.ar/sites/default/files/2025-10/778.pdf
- Belcic, I., & Stryker, C. (2025, 12 de septiembre). ¿Qué es el aprendizaje supervisado? IBM. https://www.ibm.com/mx-es/think/topics/supervised-learning
- Géron, A. (2022). Hands-on Machine Learning with Scikit-Learn, Keras, and TensorFlow. O'Reilly Media, Inc.
- Kavlakoglu, E. (2021, 2 de noviembre). ¿Qué es un árbol de decisión? IBM. https://www.ibm.com/mx-es/think/topics/decision-trees
- Matthes, E. (2023). Python Crash Course. No Starch Press. https://www.w3schools.com/python/default.asp